

Choisir et configurer le service d'IA

Call To Adventure · Bloc 2 · E2 : 15 minutes

BESOIN

Un maître du jeu narratif en français et en anglais, relié à un état de jeu.

DÉMARCHE

Veille, critères de sélection, architecture et configuration.

POSITIONNEMENT

Intégration de services préexistants. Pas d'entraînement d'un modèle de génération dans ce projet.

De la demande fonctionnelle à une solution intégrable.

Raconter, proposer, agir : trois contrats

L'IA intervient dans un moteur dont les règles restent côté serveur.

NARRATION

État + action + contexte
documentaire → suite de
l'aventure en FR ou EN.

CHOIX

Exactement 3 actions distinctes.
6 mots maximum par action.
Structure validée par Pydantic.

DÉCISIONS

Objectifs et salle : sorties typées.
Combat, soin et dégâts : outils
autorisés et règles déterministes.

Une sortie grammaticalement correcte peut rester incorrecte pour le jeu.

Définir la réussite avant de comparer

Les valeurs suivantes sont des objectifs documentés, pas des scores mesurés.

QUALITÉ

100 % de sorties structurées valides.
Au moins 90 % de réussite sur le jeu de cas.
Relecture humaine FR / EN.

SERVICE

Objectif p95 inférieur à 30 s.
Disponibilité logique visée : 99 %.
Échec contrôlé sans perte d'état.

CONTRAINTES

Budget mensuel à renseigner.
Conditions de traitement à vérifier.
Matériel local pour les embeddings.

Séparer validité du format, qualité de la réponse et disponibilité du service.

Une veille à rattacher aux décisions

Trame proposée ; les preuves de veille ne figurent pas dans le dépôt consulté.

THÈMES

Sorties structurées et outils.
RAG et évaluation.
Sécurité, données personnelles,
accessibilité et sobriété.

MÉTHODE PROPOSÉE

1 h hebdomadaire.
Agrégateur RSS + journal daté.
Auteur, date et fiabilité.
Recoupement des informations.

PREUVE ATTENDUE

Une synthèse accessible.
Une recommandation argumentée.
Une décision liée au projet.
Une trace de partage effective.

À compléter avec votre veille réelle ; aucune synthèse diffusée n'est inventée.

Comparer sur un protocole identique

Le benchmark réel de plusieurs modèles reste à réaliser.

MODÈLE HÉBERGÉ ACTUEL

Intégré dans le code.
Structure, langue, latence et coût à mesurer.
Choix encore provisoire.

SECOND SERVICE HÉBERGÉ

Candidat exact à nommer.
Même dataset et même révision.
Comparer les capacités requises et les conditions de traitement.

GÉNÉRATION LOCALE

Option à étudier.
Matériel et latence à mesurer.
Données locales ; exploitation à assurer.

Aucun service n'est déclaré meilleur sans résultats comparables.

Une génération hébergée, un RAG local

Décision d'architecture déjà documentée dans le projet.

GÉNÉRER

Service OpenAI-compatible



Narration, choix et décisions

Modèle piloté par configuration.

RETROUVER

JSON de lore → fragments



Embeddings Ollama → Chroma



Contexte filtré par aventure.

ORCHESTRER

LangGraph



Transitions explicites



Outils et moteur de jeu.

Localiser les embeddings ne signifie pas que le contexte reste entièrement local.

Rendre la configuration explicite

Valeurs par défaut du code ; l'environnement peut les remplacer.

GÉNÉRATION

Modèle : OPENAI_MODEL.
Clé dans l'environnement.
Timeout d'appel : 30 s.
Métadonnées sans clé secrète.

RETRIEVAL

RAG_ENABLED configurable.
Ollama : hôte local par défaut.
Embeddings : mxbai-embed-large.
Timeout : 10 s ; 3 tentatives.

FRONTIÈRE API

Choix : 1 000 caractères max.
Quota par défaut : 20 tours par utilisateur et par heure.
Validation de configuration.

Les paramètres décrivent le déploiement ; les secrets restent hors des supports.

Préparer le contexte avant la génération

Vérification locale du corpus : 57 fragments préparés.

CORPUS

6 fichiers de personnages.
3 fichiers de lieux.
57 fragments au dry-run.
Métadonnées de source.

À L'EXÉCUTION

Requête contextualisée.
Recherche filtrée par aventure.
Passages injectés au prompt.
Cache selon le service.

EN CAS D'ÉCHEC

Contexte vide et poursuite du jeu.
Échec visible dans les métriques.
Qualité narrative à surveiller.

Le dry-run vérifie la préparation ; il ne mesure ni les embeddings ni le rappel du RAG.

Maîtriser coûts, données et dépendances

Des arbitrages à chiffrer avant une sélection définitive.

COÛT

Tours × appels par tour × tokens
moyens × tarifs.
Ajouter hébergement, stockage et
calcul local.

DONNÉES

Décrire ce qui entre dans les
prompts. Vérifier les conditions du
fournisseur et les règles de
conservation.

SOBRIÉTÉ

Limiter le contexte utile.
Réutiliser les embeddings.
Comparer qualité et ressources.
Bilan environnemental non
mesuré.

Le registre des coûts et l'analyse fournisseur restent à compléter avec des données datées.

Une solution configurée, une sélection à étayer

Passer de l'architecture à la preuve de pertinence.

C6

Relier le dossier de veille.
Ajouter synthèses datées et décisions réellement prises.

C7

Besoins et protocole présents.
Comparer au moins deux candidats.
Compléter budget, données et critères environnementaux.

C8

Configuration et RAG préparés.
Prouver la connectivité réelle et la génération dans un environnement de démonstration.

Transition E3 : exposer, intégrer, tester et surveiller le composant.