

Choisir comment évaluer les LLM en cybersécurité

Alternance : veille, sélection de benchmarks et application d'évaluation.

BESOIN

Évaluer les modèles selon les usages cyber de l'entreprise et leurs performances.

VEILLE / SÉLECTION

Environ 10 benchmarks examinés.
Open source ou utilisables gratuitement.
Critères de scoring, adaptation et licence.

MISE EN ŒUVRE

Application de benchmark cyber et performance.
Scores et métriques enregistrés en base.

Distinguer sélection du dispositif d'évaluation et sélection du modèle.

Évaluer la pertinence et les contraintes d'usage

Deux dimensions complémentaires de l'évaluation.

CAPACITÉS CYBER

Mesurer les modèles sur des tâches en lien avec les usages réels de l'entreprise.

PERFORMANCE

P50, P95, P99.
Vitesse et concurrence.
Définir la charge et les conditions de mesure.

DÉCISION

Comparer les résultats aux contraintes métier.
Modèles évalués et recommandation finale à documenter.

Un score cyber élevé ne suffit pas si le service ne tient pas la charge requise.

Sélectionner des évaluations adaptées

Critères de sélection explicitement indiqués par le candidat.

SCORING

Exclure LLM-as-judge.
Exclure human-as-judge pour le calcul des scores.
Montrer le mécanisme retenu.

PERTINENCE

Adaptabilité aux usages cyber réels de l'entreprise.
Périmètre et limites des tâches à préciser.

ACCÈS / LICENCE

Open source ou usage gratuit.
Compatibilité de licence étudiée.
Gratuité et droits de réutilisation distingués.

Un score sans juge reste à examiner pour sa validité et ses biais.

Environ dix benchmarks cyber étudiés

Une recherche comparative orientée vers un besoin d'entreprise.

RECENSER

Identifier les benchmarks ouverts ou utilisables gratuitement.
Conserver les sources et versions consultées.

ANALYSER

Comparer scoring, pertinence métier, adaptabilité et licence.
Expliciter les exclusions.

RESTITUER

Joindre la matrice de comparaison et la synthèse.
Préciser dates, rythme de veille et partage réel.

L'étude est réalisée ; son organisation régulière et sa diffusion restent à documenter.

Un modèle exécuté, un runner extensible

Modèle de la famille Qwen ; référence exacte à confirmer.

EXÉCUTION

Un seul modèle disponible dans l'architecture entreprise a été exploité à ce stade.
Preuves de runs disponibles.

CONCEPTION

Script conçu pour être agnostique des modèles et des benchmarks cyber.
Interfaces de configuration à montrer.

LIMITE C7

Pas encore de comparaison empirique entre plusieurs modèles.
Distinguer contrainte d'architecture et recommandation de service.

L'extensibilité du runner n'est pas une comparaison multi-modèles déjà réalisée.

Une génération hébergée, un RAG local

Décision d'architecture déjà documentée dans le projet.

GÉNÉRER

Service OpenAI-compatible



Narration, choix et décisions

Modèle piloté par configuration.

RETROUVER

JSON de lore → fragments



Embeddings Ollama → Chroma



Contexte filtré par aventure.

ORCHESTRER

LangGraph



Transitions explicites



Outils et moteur de jeu.

Localiser les embeddings ne signifie pas que le contexte reste entièrement local.

Rendre la configuration explicite

Valeurs par défaut du code ; l'environnement peut les remplacer.

GÉNÉRATION

Modèle : OPENAI_MODEL.
Clé dans l'environnement.
Timeout d'appel : 30 s.
Métadonnées sans clé secrète.

RETRIEVAL

RAG_ENABLED configurable.
Ollama : hôte local par défaut.
Embeddings : mxbai-embed-large.
Timeout : 10 s ; 3 tentatives.

FRONTIÈRE API

Choix : 1 000 caractères max.
Quota par défaut : 20 tours par utilisateur et par heure.
Validation de configuration.

Les paramètres décrivent le déploiement ; les secrets restent hors des supports.

Préparer le contexte avant la génération

Vérification locale du corpus : 57 fragments préparés.

CORPUS

6 fichiers de personnages.
3 fichiers de lieux.
57 fragments au dry-run.
Métadonnées de source.

À L'EXÉCUTION

Requête contextualisée.
Recherche filtrée par aventure.
Passages injectés au prompt.
Cache selon le service.

EN CAS D'ÉCHEC

Contexte vide et poursuite du jeu.
Échec visible dans les métriques.
Qualité narrative à surveiller.

Le dry-run vérifie la préparation ; il ne mesure ni les embeddings ni le rappel du RAG.

Conserver et interpréter chaque campagne

Un modèle exécuté ; cyber et performance mesurés par le même outil.

RÉSULTATS

Scores de benchmarks cyber.
P50 / P95 / P99.
Vitesse et concurrence.
Enregistrement en BDD.

RUNNER AGNOSTIQUE

Prise en compte de différents
modèles et benchmarks prévue par
conception.
Montrer l'interface de configuration.

PREUVES À JOINDRE

Référence Qwen confirmée.
Une campagne réelle.
Conditions, unités et erreurs.
Schéma des résultats stockés.

Présenter les scores du modèle disponible, sans fabriquer de classement.

Une veille concrète et un outil d'évaluation opérationnel

La comparaison porte aujourd'hui sur les benchmarks, pas encore sur plusieurs modèles.

C6

Environ dix benchmarks étudiés.
Scoring, usage et licences comparés.
Matrice et traces de partage à joindre.

C7

Un modèle imposé par sa disponibilité.
Comparaison et recommandation de services encore à étayer.

C8

Configuration du jeu en complément.
Joindre l'environnement et la référence exacte du modèle entreprise.

Le point fort nouveau est C12 ; la limite de comparaison C7 reste explicite.