


Bloc 2 · Intégrer des modèles et services d'IA

E2 + E3 · Veille, sélection, intégration et évaluation des LLM cyber



Un bloc, trois réalisations distinctes



E2

choisir et paramétrer un dispositif d'évaluation/service IA

Veille benchmark, critères, limite de comparaison multi-modèles, configuration IA/RAG.

E3

mettre en service, intégrer, surveiller, tester et livrer

API REST, contrôles d'accès, intégration Tines, observabilité, benchmark automatisé, CI/CD.

1 - Recenser

Environ 10 benchmarks cyber identifiés
Sources ouvertes ou utilisables gratuitement
Versions et dates conservées

2 - Qualifier

Auteur, fraîcheur, documentation
Lien avec les usages cyber
Risques de biais ou d'inadaptation

3 - Comparer

Scoring sans LLM-as-judge
Adaptabilité, licence, contraintes
Raisons d'exclusion explicites

4 - Restituer

Matrice de comparaison
Synthèse communiquée
Décision argumentée

Scoring

Mécanisme mesurable
Exclusion du LLM-as-judge pour les scores
Pas de jugement humain dans le calcul

Pertinence cyber

Tâches liées aux usages réels
Périmètre et limites explicites
Validité du benchmark discutée

Accès / licence

Open source ou gratuité étudiée
Droits de réutilisation distingués
Contraintes d'exploitation notées

Performance

Latence P50/P95/P99
Concurrence, vitesse, erreurs
Conditions de charge constantes


C6 - De la veille à une matrice exploitable

Cybersecurity Benchmark Comparison — Advens											
										Scoring criterion	Weight
Purpose: compare all discussed benchmarks against the requirements in the internal specification. Research status reflects publicly available information reviewed on 2026-08-06; licensing conclusions are screening notes, not legal advice.										Blue Team proximity	30%
Benchmark	Blue Team 0-3	Automatic 0-3	Extensible 0-3	Local0-3	License 0-3	Coverage 0-3	Weighted score /100	Specification gate	Current recommendation	Automatable scoring	25%
CyberSecEval 3 / 4	1	2	2	2	2	2	57	PASS / REVIEW	Use selected modules only	Extensibility	15%
CyberSOCEval	3	3	2	3	2	1	87	PASS / REVIEW	Strong component candidate	Local reproducibility	10%
CTIBench	3	3	3	3	0	2	83	BLOCKED — license/terms	Technically strong; legally blocked pending review	License suitability/confidence	15%
SecBench	1	2	2	3	0	1	48	BLOCKED — license/terms	Supplementary MCQ only, pending license	Functional coverage	5%
SOCBench	3	3	3	3	3	2	98	PASS / REVIEW	Top technical candidate		
Cyber Defense Benchmark	3	3	2	2	2	2	85	PASS / REVIEW	Advanced future candidate	Rating	Meaning
											3 Strong match / verified


Extrait de la matrice de comparaison des benchmark Cyber

Complément : Session « Partage de connaissance » toutes les semaines avec l'équipe pour restitution sur l'état de l'art.


C6-C7 · Réalisation d'un benchmark LLM cyber/performance



Résultats stockés en .csv et base de donnée



Architecture du projet benchmark



Visualisation d'un run dans la console

C6-C7 · Réalisation d'un benchmark LLM cyber/performance

Rows: 11						Filter 11 rows...		Upgrade t							
	id		run_id	timestamp	benchma...	model	version	category	prompt_id	nb_quest...	correct	accuracy	elapsed_seconds		
	id		Filter...	Filter...	Filter...	Filter...	Filter	Filter	Filter	Filter	Filter	Filter	Filter...		
1	1		8b910981-eff9-409f-8efc-35603d57f55f	2026-09-11T09:07:19.648596	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	5	0.5	2.700135070830		
2	2		5d8d8606-8dc0-4850-8efb-c00e360a329b	2026-09-14T16:33:13.811856	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	8	0.8	2.22679472342		
3	3		b9dd0189-87b6-4564-85a1-786e25b52c76	2026-09-14T16:33:17.956792	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	8	0.8	2.215794518589		
4	4		24f83e6d-27db-46be-8bc8-8ef967f441cf	2026-09-14T16:33:21.991645	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	9	0.9	2.16182715073		
5	5		fb996841-83eb-4e86-ae73-21f2c38b076f	2026-09-14T16:33:26.242713	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	8	0.8	2.459676016122		
6	6		48eb8122-2cc8-439a-b1dc-c1e6026304ab	2026-09-14T16:33:30.675329	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	7	0.7	2.613316956907		
7	7		f3d54ed3-92e1-4dff-893f-d1ca03334a5	2026-09-14T16:33:34.845916	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	9	0.9	2.168885033577		
8	8		ed5205d8-7566-48ee-930f-abe76d1d148f	2026-09-14T16:33:39.083050	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	7	0.7	2.209065601229		
9	9		f2c6/0f/-41/3-405b-be1a-9010d3149b5a	2026-09-14T16:33:43.259601	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	8	0.8	2.18408307805		
10	10		912190a4-1e01-486a-b11d-6517ee808626	2026-09-14T16:33:47.359740	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	8	0.8	2.178931031376		
11	11		142b65b9-778d-45e3-83b4-2f3c26e1927e	2026-09-14T16:33:51.645701	CTIBench	Qwen/Qwen3.8-	1.0	threat_intelligence	ctibench_mcq_v1	10	9	0.9	2.275208350270		

Résultats des runs cyber (score comme métrique principale)

	run_id	model	scenario	nb_reque...	concurr...	successf...	errors	error_rate	elapsed_seconds	avg_latency	p50_latency	p95_latency	p99_latency	requests_per_s...
	Filter...	Filter...	Filter	Filter	Filter	Filter	Filter	Filter	Filter...	Filter...	Filter...	Filter...	Filter...	Filter...
1	5127ce9b-c156-4c4a-a20a-140bb483bbf5	Qwen/Qwen3.8-27B-FP8	short	50	1	50	0	0	23.169499348849058	0.4632823972404003	0.45162716321647167	0.4548618007451296	0.7549527633935201	2.158009512729663
2	07b52a2d-58ae-4241-a805-e24b3b935959	Qwen/Qwen3.8-27B-FP8	short	50	1	50	0	0	31.57681655883789	0.6314438696950674	0.40830295346677303	2.0716702392324806	2.907738270051776	1.58344017696760...
3	dffaf82b-4c12-40a2-bdd1-6d4fa202c1ae	Qwen/Qwen3.8-27B-FP8	short	50	1	50	0	0	20.83416498452425	0.4164016220718622	0.4037108812481165	0.411951381154358...	0.7176893061771977	2.399904197607167
4	76d1d2b6-a435-498a-965a-3214194b0b...	Qwen/Qwen3.8-27B-FP8	short	50	1	50	0	0	24.013111621141434	0.480121737867593...	0.40648068487644196	0.8630673587322227	1.7791320831328603	2.08219579323403...
5	25111509-6568-42cf-a9d8-65c732ff43a9	Qwen/Qwen3.8-27B-FP8	short	50	1	50	0	0	21.06100332736969	0.4211044205725193	0.40904045291244984	0.4150413965806365	0.7122353079169977	2.37405593754514...
6	afbe7958-aa15-4eb7-a39f-cfa8652b3d23	Qwen/Qwen3.8-27B-FP8	short	10	5	10	0	0	1.8768125623464584	0.9345163375139236	0.936078168451786	1.217308263666928	1.2184236696735025	5.328182579669885
7	73fbb6b3-b683-45c2-ad5f-a41eb1542116	Qwen/Qwen3.8-27B-FP8	short	23	3	23	0	0	4.155130889266729	0.5235890843298124	0.43090325593948364	1.0551916271448136	1.0584131829440593	5.535325026562254
8	427ba738-d53a-4551-8baf-8dba8dcefcf8	Qwen/Qwen3.8-27B-FP8	short	10	2	10	0	0	2.6822176165878773	0.5357242878526449	0.4194979667663574	0.9924197195097804	0.9937619894370436	3.728258265905089
9	9eecffc4-c992-44af-a604-13035630586a	Qwen/Qwen3.8-27B-FP8	short	19	11	19	0	0	2.195527743548155	1.0874146587754552	1.2284046523272991	1.7611402131617069	1.7611858697235585	8.653955777071815
10	2efa342d-1eec-463d-a022-ea16d2bb588e	Qwen/Qwen3.8-27B-FP8	short	19	11	19	0	0	2.0810000896453857	1.0192866731238992	1.086859431117773	1.6468083869665862	1.6494162263721228	9.13022545964316
11	96d66f9e-2d05-4cf4-ac50-5f369554d0ae	Qwen/Qwen3.8-27B-FP8	short	20	3	20	0	0	3.615454263985157	0.5213300747796893	0.4342874977737665	1.0413697415962815	1.0423268895223736	5.53180832605938...
12	9f42eb66-88c2-41bd-baaa-4783569adc32	Qwen/Qwen3.8-27B-FP8	short	14	11	14	0	0	1.678132675588131	1.1314004574503218	1.1591126825660467	1.6706365676596762	1.672294790185988	8.342606161991009
13	dd75638c-27d4-4c42-a1b1-21e9c16f9718	Qwen/Qwen3.8-27B-FP8	short	15	6	15	0	0	2.0312098562717438	0.721315324306488	0.4758450426161289	1.1194517057389022	1.1217031904309989	7.38476133014256
14	917173e2-3129-46db-8ca2-f542f8dc139	Qwen/Qwen3.8-27B-FP8	short	16	8	16	0	0	1.6860100999474525	0.8370220442302525	0.8367437943816185	1.13773656450212	1.144420088455081	9.48986011441964
16	aa8419e4-5689-4771-b7c5-0b518c963710	Qwen/Qwen3.8-27B-FP8	short	23	5	23	0	0	3.1320503056049347	0.63618293436973	0.5334168672561646	1.0898137256503104	1.0931353515386582	7.343432498143641


Résultats des runs performances

Démontré

- Un runner conçu pour recevoir différents modèles et benchmarks
- Une application qui lance des runs paramétrables et stocke les résultats
- Un modèle de la famille Qwen exécuté dans l'architecture disponible
- Des métriques cyber (score contre CTI et Malware analysis) et performance (P50, P95, P99) exploitables

Limite assumée

- Pas encore de comparaison empirique entre plusieurs modèles



E2 · Bilan : choisir et paramétrer sans sur-vendre

En 15 minutes, l’objectif est de convaincre que la démarche de choix est structurée et que le service est paramétré.

C6

Veille

Benchmarks cyber recensés, sources qualifiées, matrice comparative, synthèse diffusée

C7


Benchmark & recommandation

Critères de scoring, pertinence, performance, licence ; limite multi-modèles explicite

C8

Paramétrage

Service IA, RAG, variables d’environnement, timeouts, quotas, documentation



C9 - API REST : trois points d'entrée documentés

Le contrat versionné donne la frontière de l'API : ce qui est public, authentifié, ou protégé par session.

GET /api/v1/ai/health/

Public
Indique l'état de configuration
Ne prouve pas seul un appel fournisseur réussi

```
{"status": "configured", "generation_configured": true, "retrieval_configured": false}
```

GET /api/v1/ai/configuration/

Authentifié
Expose les modèles et limites utiles
Aucune clé ni prompt renvoyés


```
{"configuration": {"generation_model": "gpt-5.6-luna", "reasoning_effort": "low", "rag_enabled": false, "embedding_model": "mxbai-embed-large:latest", "request_timeout_seconds": 30.0, "provider_max_retries": 0, "embedding_timeout_seconds": 10.0, "embedding_max_attempts": 3, "max_input_chars": 1000, "turns_per_user_per_hour": 20}}
```

POST /api/v1/games/{id}/turns/

Session + CSRF
Avance une sauvegarde possédée
Valide entrées et choix utilisateur
Preuve de concept dans l'usage actuel

C9 - Contrôles d'accès : protéger avant d'appeler le modèle

Les contrôles se placent avant l'appel IA : un utilisateur non autorisé ne doit pas consommer le service ni révéler l'existence d'une partie.



Ce que les tests prouvent

Des contrôles précis existent et sont testés. Ils ne constituent pas un audit de sécurité complet : c'est une frontière applicative robuste pour le périmètre présenté.

C10 - Sorties et erreurs : fiabiliser l'usage IA

E3 - C10

Une réponse HTTP réussie ne suffit pas : il faut distinguer disponibilité, validité de schéma et utilité fonctionnelle.

Sorties typées

ChoiceOutput : 3 choix distincts
Chaque choix ≤ 6 mots
Objectifs et progression : schémas dédiés

```
class GoalEvaluationOutput(BaseModel):
    completed_goals: List[str] = Field(
        default_factory=list,
        description="Goals from the provided ongoing goals list that are now clearly complete.",
    )

class RoomCompletionOutput(BaseModel):
    room_completed: bool = Field(
        default=False,
        description="Whether the latest resolved narrative clearly completes the current room objective.",
    )
    reason: str = Field(
        default="",
        description="Short explanation grounded in the latest narrative.",
    )
```

Réponses structurées validée par Pydantic

```
class ChoiceOutput(BaseModel):
    choices: List[str] = Field(
        description="Exactly three distinct short player actions."
    )

    @field_validator("choices")
    @classmethod
    def validate_choices(cls, value: List[str]) -> List[str]:
        if len(value) != 3:
            raise ValueError("choices must contain exactly 3 items")

        cleaned = [item.strip() for item in value]

        if any(not item for item in cleaned):
            raise ValueError("choices cannot contain empty strings")

        if any(len(item.split()) > 6 for item in cleaned):
            raise ValueError("each choice must be at most 6 words long")

        lowered = [item.lower() for item in cleaned]
        if len(set(lowered)) != 3:
            raise ValueError("choices must be distinct")

        return cleaned
```

```
choicer_chain = LazyRuntimeObject(
    lambda: CHOOSER_TEMPLATE | get_llm().with_structured_output(ChoiceOutput)
)

choicer_chain_fr = LazyRuntimeObject(
    lambda: CHOOSER_TEMPLATE_FR | get_llm().with_structured_output(ChoiceOutput)
)
```

Reprises contrôlées

Retry sur erreurs transitoires
Délais et tentatives bornés
Erreur contrôlée après épuisement

Montrer : `llm_resilience.py`

C10 · Sorties et erreurs : fiabiliser l'usage IA

E3 · C10

État applicatif

Une génération échouée n'avance pas la partie


```
if result["mode"] == "service_unavailable":
    return JsonResponse(
        {
            "mode": "service_unavailable",
            "error": settings.LLM_SERVICE_UNAVAILABLE_MESSAGE,
            "player": player_sheet,
        },
        status=settings.LLM_SERVICE_UNAVAILABLE_STATUS_CODE,
    )

if result["mode"] == "gameover":
    ADVENTURE_RESULTS.labels(result="defeat").inc()
    persist_game(request, state, finish=True)
    return JsonResponse({
        "mode": "gameover",
        "player": player_sheet,
    })


if result["mode"] == "adventure_victory":
    ADVENTURE_RESULTS.labels(result="victory").inc()
    persist_game(request, state, finish=True)
    return JsonResponse({
        "mode": "adventure_victory",
        "player": player_sheet,
    })

# Save updated state
persist_game(request, state)
```

Une génération échouée n'appelle pas la fonction de sauvegarde persist_game()



La chaîne collecte des signaux techniques et fonctionnels sans exposer les prompts, identités ou sessions dans les labels.



Prometheus

call-to-aidventure-django

1 / 1 up

Endpoint	Labels	Last scrape	State
http://host.docker.internal:8000/metrics	application="call-to-aidventure"environment="development"instance="host.docker.internal:8000"job="call-to-aidventure-django">	4.022s ago31ms	UP

aidventure-ai

/etc/prometheus/alerts.yml

FIRING (1)

INACTIVE (4)

AidventureAIServiceUnavailable

AidventureAIHighLatency

AidventureStructuredOutputFailures

AidventureRAGErrors


AidventureTestAlert

FIRING (1)

/9090

observability/metrics.py

Dashboard Grafana



C12 - Tests automatisés : runs cyber + performance

Le point fort de l'alternance : une application lance des benchmarks et conserve les résultats pour interprétation.

Cyber

Benchmarks retenus
Scores produits
Mécanisme sans juge humain ni LLM pour le calcul

Performance

P50 / P95 / P99
Vitesse et concurrence
Charge, erreurs et durée du test

Persistance

Résultats en base
Contexte du run conservé
Interprétation des limites

C13 - Livraison continue : contrôler avant de déployer

Le workflow Block 2 AI component automatise les contrôles et produit un artefact traçable.



C13 - Livraison continue : contrôler avant de déployer



deterministic-quality

succeeded last week in 40s

- > ☒ Set up job
- > ☒ Run actions/checkout@v4
- > ☒ Run astral-sh/setup-uv@v6
- > ☒ Run actions/setup-python@v5
- > ☒ Run uv sync --frozen
- > ☒ Run uv run python db/sqlite/setup_db.py --reset
- > ☒ Run uv run ruff check src tests
- > ☒ Run uv run python src/django/manage.py check
- > ☒ Run uv run python -m retrieval.ingest --dry-run
- > ☒ Run uv run python -m evaluation.runner --output evaluation/report.json
- > ☒ Run uv run coverage run src/django/manage.py test game tests
- > ☒ Run uv run coverage report
- > ☒ Run actions/upload-artifact@v4
- > ☒ Post Run actions/setup-python@v5
- > ☒ Post Run astral-sh/setup-uv@v6
- > ☒ Post Run actions/checkout@v4
- > ☒ Complete job

1	▶ Run uv run coverage report				
14	Name	Stmts	Miss	Cover	Missing
15	-----				
16	src/agents/game_master_graph.py	352	102	71%	114-115, 765-808
17	src/agents/llm_resilience.py	79	9	89%	37, 50, 5
18	src/agents/llm_runtime.py	42	6	86%	32, 37, 4
19	src/agents/prompts/story.py	56	25	55%	20-23, 45
20	src/agents/prompts/story_fr.py	26	13	50%	14, 27, 4
21	src/agents/runtime_config.py	64	8	88%	18-19, 23
22	src/agents/schemas.py	23	11	52%	13-28
23	src/agents/tools.py	15	2	87%	16, 20
24	src/django/game/ai_api.py	73	17	77%	20, 35-36
25	src/django/game/dataset_api.py	73	14	81%	28, 37-38
26	src/django/game/management/commands/check_ai_services.py	31	31	0%	1-43
27	src/django/game/management/commands/cleanup_retention.py	20	1	95%	23
28	src/django/game/management/commands/export_user_data.py	23	5	78%	20-21, 47
29	src/django/game/models.py	26	2	92%	15, 36
30	src/django/game/services/game_engine.py	87	32	63%	22-23, 27
31	src/django/game/views.py	404	69	83%	45-46, 98
32	src/observability/llm_callback.py	20	14	30%	14-28
33	src/retrieval/chunker.py	65	20	69%	50-62, 66
34	src/retrieval/client.py	28	16	43%	17-20, 24
35	src/retrieval/embedder.py	42	28	33%	25-61
36	src/retrieval/ingest.py	60	60	0%	1-122
37	src/retrieval/schemas.py	113	7	94%	138, 163, 7
38	src/retrieval/service.py	84	21	75%	39, 61, 7
39	-----				
40	TOTAL	2942	513	83%	

Bilan : couverture des compétences C6 à C13

C6	Veille	Sources + matrice benchmarks + synthèse
C7	Sélection	Critères, exclusions, recommandation, limite multi-modèles
C8	Paramétrage	OPENAI_MODEL, RAG, timeouts, quotas, documentation
C9	API IA	OpenAPI, endpoints, auth/session/CSRF, tests
C10	Intégration	Application → API/Tines → réponse exploitable
C11	Monitoring	Prometheus, Grafana, alertes, SLO, métriques RAG
C12	Tests modèle	Benchmarks cyber/perf, résultats en BDD, interprétation
C13	CI/CD	Workflow, artefact Docker, smoke test, rapport conservé